Wine Quality Predictor

Ingvild Sirnes, 30.10.2026

1 PROBLEMET

1.1 Bakgrunn og formål

Kvaliteten på vin vurderes vanligvis gjennom en kombinasjon av fysikalsk-kjemiske analyser og sensoriske vurderinger utført av mennesker. Kjemiske analyser av vinen kan blant annet måle alkoholinnhold, tetthet og pH, mens sensoriske vurderinger benytter menneskelige eksperter til å bedømme vinens egenskaper (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009).

Smak er den menneskelige sansen vi forstår oss minst på, og vinklassifisering er derfor en vanskelig oppgave. I tillegg er forholdet mellom de kjemiske egenskapene til vin og menneskers smaksopplevelse komplekse (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009).

I forskningsartikkelen *Modeling wine preferences by data mining from physicochemical properties* (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009) undersøkes det hvordan datagraving og maskinlæring kan benyttes til å predikere menneskelige smakspreferanser, basert på de analytiske dataene fra vinprosessen. Slike metoder kan være nyttige for å støtte vinprodusenter og fagpersoner i kvalitetsvurderingen, men kan også være nyttig for forbrukerne (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009).

Med utgangspunkt i denne artikkelen og det tilhørende datasettet, er formålet med dette prosjektet å utvikle et produkt som kan estimere vinkvalitet basert på vinens fysikalsk-kjemiske egenskaper med hjelp av maskinlæring. Prosjektet benytter et eksisterende datasett med målinger fra rødvin og hvitvin fra Vinho Verde-regionen i Portugal (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009).

Resultatet av prosjektet er en interaktiv webapplikasjon der brukeren kan velge vintype, legge inn vinens kjemiske egenskaper og få en estimert kvalitetsscore fra en trent maskinlæringsmodell.

1.2 Hvorfor maskinlæring?

Kvalitetsvurdering av vin krever i dag både kjemiske analyser og sensoriske vurderinger som utføres av mennesker. Dette kan være tidskrevende og komplisert, og vurderingene kan påvirkes av individuelle forskjeller på smak (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009).

Ved å bruke maskinlæring kan vi analysere flere kjemiske egenskaper samlet, og identifisere mønstre og sammenhenger mellom disse og tidligere kvalitetsvurderinger. Modellen kan dermed brukes i tillegg til tradisjonelle vurderingsmetoder, men den er ikke ment til å erstatte menneskelige smaksvurderinger.

1.3 Problemstilling

Prosjektet tar utgangspunkt i følgende problemstilling:

I hvilken grad kan maskinlæring brukes til å estimere vinkvalitet basert på vinens fysikalsk-kjemiske egenskaper?

Oppgaven er formulert som et regresjonsproblem der målet er å predikere en numerisk kvalitetsverdi basert på 11 kjemiske egenskaper, samt vintypen (rød eller hvit). Kvalitetsvurderingen i datasettet er basert på sensoriske data mens inputvariablene er hentet fra fysikalsk-kjemiske tester (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009).

1.4 Avgrensning og evalueringsmål

Prosjektet bruker som nevnt over det eksisterende datasettet (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009) med kjemiske målinger og sensoriske kvalitetsvurderinger.

For å evaluere modellen sin prediksjonsevne benyttes tre forskjellige måleparametere:

- *Mean Absolute Error (MAE)* måler den gjennomsnittlige absolutte forskjellen mellom modellens prediksjoner og de faktiske kvalitetsverdiene (Reddy, 2026). Dette er det viktigste evalueringsmålet i prosjektet.

- *Root Mean Squared Error (RMSE)* måler kvadratroten av gjennomsnittlig kvadrert prediksjonsfeil. Ved å kvadrere feil gir den større straff ved feil, noe som gjør den følsom for avvik (Reddy, 2026).

- *R^2 (R-kvadrat)* beskriver hvor mye av variasjonen i kvalitetsverdiene modellen klarer å forklare, sammenlignet med en modell som kun predikerer gjennomsnittet i datasettet. Den gir med andre ord innsikt i hvor godt modellen fanger opp underliggende datamønstre (Reddy, 2026).

For å ha et sammenligningsgrunnlag benyttes en enkel baseline-modell (DummyRegressor) som alltid predikerer gjennomsnittlig kvalitetsverdi fra treningsdataene. Modellene sammenlignes med denne for å undersøke om de klarer å lære sammenhenger mellom de kjemiske egenskapene og vinkvaliteten.

Dersom den valgte modellen oppnår lavere MAE enn baseline-modellen på testsettet (DummyRegressor) , og webapplikasjonen fungerer som forventet ved at brukeren kan legge inn måleverdier og få en kvalitetsestimering, vurderes prosjektet som vellykket.

Prediksjonen den trente modellen gir er kun et estimat basert på kjemiske målinger og ikke en direkte vurdering av vinens smak.

2 DATA

2.1 Datakilde og databeskrivelse

Som nevnt tidligere benytter prosjektet datasettet *Wine Quality* fra UCI Machine Learning Repository (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009). Datasettet består av to separate datasett. Ett med rødvin og ett med hvitvin, begge av typen Vinho Verde fra Nord-Portugal. Settet inneholder totalt 6497 observasjoner, der 1599 er rødviner og 4898 er hvitviner (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009).

Til et prosjekt av denne størrelsen er 6497 vinobservasjoner tilstrekkelig for å utvikle og sammenligne ulike regresjonsmodeller. Datasettet gir et godt grunnlag for å undersøke sammenhengen mellom vinens kjemiske egenskaper og de menneskelige kvalitetsvurderingene. Men flere observasjoner og særlig av viner med sjeldne kvalitetsverdier, kunne gitt et bedre grunnlag for modelltrening.

Hver observasjon i datasettet representerer en vinprøve og inneholder 11 fysikalsk-kjemiske egenskaper. Disse er som følger: *fixed acidity, volatile acidity, citric acid, residual sugar, chlorides, free sulfur dioxide, total sulfur dioxide, density, pH, sulphates og alcohol.* Disse er numeriske måleverdier som utgjør modellens inputvariabler (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009). I tillegg ble det opprettet en ny kategorisk variabel: *wine_type*, som skiller mellom rødvin og hvitvin, og modellen fikk totalt 12 inputvariabler.

Målet med prosjektet er å predikere variabelen *quality* som inneholder en sensorisk kvalitetsvurdering på en skala fra 0 til 10. De observerte verdiene i datasettet går midlertidig fra 3 til 9.

Siden hver observasjon har både inputverdier og en tilhørende kvalitetsvurdering egnes datasettet godt til supervised learning. Vi behandler kvalitetsverdien som en numerisk variabel i prosjektet og formulerer derfor problemet som en regresjonsoppgave fremfor en klassifiseringsoppgave.

Datasettet inneholder både måleverdier og tilhørende labels. Det er derfor ikke nødvendig å samle inn nye data eller gjennomføre egne sensoriske vurderinger. Vi må derfor gå ut fra at kvalitetsverdiene i datasettet er pålitelige og at usikkerhet tilknyttet konsistensen i de opprinnelige vurderingene må regnes som en begrensning. Datasettet har også veldig ujevn fordeling av kvalitetsverdier. Det er betydelig flest observasjoner i kategoriene 5 og 6 og svært få observasjoner i ytterkantene. Dette kan gjøre det vanskeligere for modellen å estimere kvaliteten på viner med svært lave eller høyre vurderinger.

2.2 Personvern og etiske hensyn

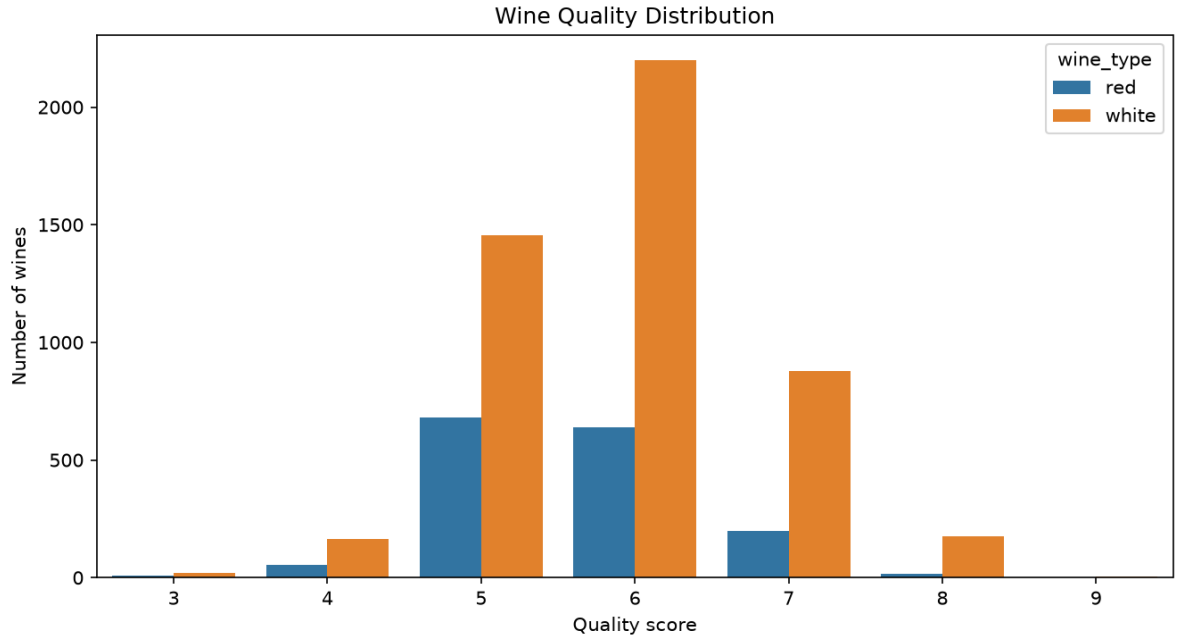
Datasettet inneholder informasjon om vinprøver og deres kjemiske egenskaper, ikke personopplysninger. Det finnes derfor ingen direkte personvernhensyn knyttet til identifisering av enkeltpersoner. Det oppgis også om at blant annet druesorter, merkenavn og salgspris ikke er inkludert i datasettet, blant annet på grunn av personvernmessige og praktiske hensyn (Cortez P. , Cerdeira, Almeida, Matos, & Reis, 2009).

En relevant etisk begrensning er at modellens prediksjoner ikke nødvendigvis representerer en objektiv vurdering av vinkvalitet. Modellen lærer sammenhenger fra eksisterende sensoriske vurderinger og resultatet avhenger derfor av kvaliteten og gyldigheten til disse vurderingene. Prediksjonen er dermed kun et estimat basert på kjemiske egenskaper og ikke en erstatning for menneskelig smaking eller en garanti for vinens faktiske kvalitet.

2.3 Databehandling og representasjon

Dataene er lagret i CSV-format og behandles ved hjelp av Python og Pandas. De to datasettene for rødvin og hvitvin ble lest inn og deretter satt sammen til ett samlet datasett. Videre ble variabelen *wine_type* lagt til for å bevare informasjon om hvilken vin som er rød og hvilken vin som er hvit.

Det ble gjennomført en utforskende dataanalyse for å undersøke kvalitetsfordelingen og sammenhenger mellom variablene. Analysen viste at datasettene ikke inneholder manglende verdier, noe som også er oppgitt på UCI sin nettside. Det var derfor ikke behov for å fylle inn eller fjerne observasjoner. Analysen viste også at kvalitetsverdiene er ujevnt fordelt, med få observasjoner av viner med svært lave og høye kvalitetsvurderinger.



Figur 1: Fordeling av kvalitetsverdiene i datasettet for rødvin og hvitvin

Før modelltreningen ble dataene delt inn i et treningssett og et testsett hvor treningssettet besto av 80% av observasjonene og testsettet besto av resterende 20%.Treningssettet ble brukt til modellutvikling og modellvalg, mens testsettet ble holdt av til den endelige evalueringen.

Forbehandlingen av dataene ble tilpasset de ulike modelltypene. For den lineære regresjonsmodellen ble det brukt en *StandardScaler* for å standardisere de numeriske variablene, slik at de fikk gjennomsnitt 0 og standardavvik 1 (sklearn, 2026). Den kategoriske variabelen *wine_type* ble kodet numerisk med *OneHotEncoder,* som oppretter egne binære kolonner for de ulike kategoriene (scikit, 2026). For Random Forest-modellen ble den kategoriske variabelen kodet på samme måte, men numerisk skalering var ikke nødvendig. Dette skyldes at Random Forest er basert på beslutningstrær, som deler data basert på terskelverdier og derfor ikke er avhengige av at inputvariablene har samme skala (Bhakta, 2026).

Forbehandlingen ble implementert som en del av modellens pipeline. På denne måten ble transformasjonene tilpasset treningsdataene og deretter brukt på testdataene, noe som bidrar til å unngå datalekkasje.

3 MODELLERING

3.1 Utforsking av modeller og baseline

Målet med modelleringsdelen av prosjektet var å utvikle en regresjonsmodell som kunne estimere vinkvalitet basert på de fysikalsk-kjemiske egenskapene til vinprøvene. Det ble utforsket tre ulike modeller: en enkel baseline-modell, lineær regresjon og random forest regressor.

Som utgangspunkt ble det etablert en baseline ved hjelp av *DummyRegressor* med strategien *mean*. Denne modellen predikerer gjennomsnittlig kvalitetsverdi fra treningsdataene for alle observasjoner, uavhengig av inputverdiene. Baseline-modellen gir et enkelt sammenligningsgrunnlag for å vurdere om de mer avanserte modellene faktisk lærer sammenhenger mellom de kjemiske egenskapene og vinkvaliteten.

Den andre modellen var lineær regresjon. Denne ble brukt til å undersøke om det finnes tilnærmet lineære sammenhenger mellom inputvariablene og kvalitetsverdiene. Modellen ble implementert med standardisering av numeriske variabler og *One-Hot Encoding* av den kategoriske variabelen *wine_type.*

Den tredje modellen var *Random Forest Regressor* med 200 beslutningstrær. Random Forest kombinerer prediksjonene fra flere beslutningstrær og kan fange opp mer komplekse og ikke-lineære sammenhenger i dataene. Modellen ble valgt som en aktuell kandidat fordi forholdet mellom kjemiske egenskaper og sensorisk vinkvalitet ikke nødvendigvis er lineære.

3.2 Modellvalg og evalueringsmetoder

Datasettet ble delt inn i et treningssett og et testsett, der 80% av observasjonene ble brukt til trening og 20% ble holdt av til testing. Dette tilsvarte henholdsvis 5197 og 1300 observasjoner. For å sammenligne modellene ble det brukt fremdelt kryssvalidering på treningssettet. Treningsdataene ble delt inn i fem deler og modellene ble trent og testet på ulike kombinasjoner av disse delene, slik at hver del ble brukt til testing én gang. Deretter ble modellene vurdert ved hjelp av *Mean Absolute Error (MAE)*, og modellen med lavest gjennomsnittlig *MAE* ble valgt.

Som nevnt tidligere måler *MAE* gjennomsnittlig absolutt avvik mellom modellens prediksjoner og de faktiske kvalitetsverdiene. En lavere verdi betyr at prediksjonene i gjennomsnitt ligger nærmere de faktiske verdiene. I tillegg ble *Root Mean Squared Error (RMSE)* og R^2 brukt ved den endelige evalueringen. RMSE måler også prediksjonsfeil, men legger større vekt på store avvik. R^2 beskriver hvor mye av variasjonen i kvalitetsverdiene modellen klarer å forklare og en verdi nærmere 1 indikerer bedre forklaringsgrad. Kryssvalideringen ga følgende resultater:

Modell	***Gjennomsnittlig MAE***	***Standardavvik***
Dummy Regressor	0.6910	0.0135
Lineær regresjon	0.5701	0.0105
Random Forest	0.4431	0.0142

Resultatene viser at *Random Forest* oppnådde lavest *MAE* i kryssvalideringen og ble derfor valgt som den endelige modellen. Den hadde også betydelig lavere prediksjonsfeil enn både baseline-modellen og lineær regresjon.

3.3 Resultater

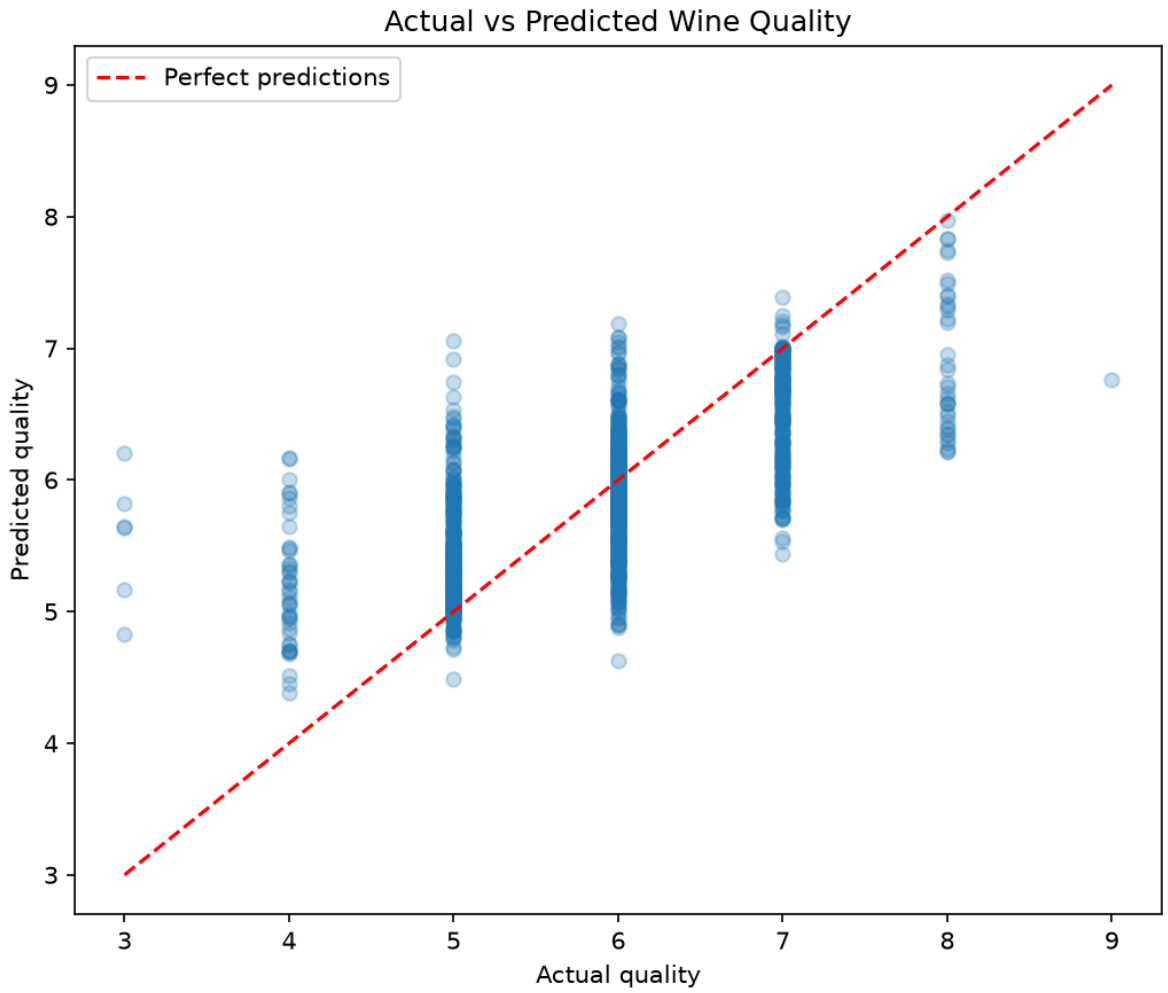
Etter modellvalget ble modellene evaluert på det separate testsettet. Testsettet hadde ikke blitt brukt under modelltreningen eller modellvalget, og ga dermed et grunnlag for å undersøke hvordan modellene presterte på data de ikke hadde sett tidligere.

Resultatet fra testsettet var som følgende:

Modell	**MAE**	**RMSE**	***R²***
Dummy Regressor	0.6691	0.8596	-0.0005
Lineær regresjon	0.5644	0.7357	0.2672
Random Forest	0.4366	0.6093	0.4974

Random Forest oppnådde best resultat på alle de tre evalueringsmetrikkene. Modellen hadde en *MAE* på 0.4366, som betyr at prediksjonene i gjennomsnitt hadde et avvik med omtrent 0.44 kvalitetsenheter fra de faktiske vurderingene. *RMSE*-verdien på 0.6093 viser at

modellen også hadde relativt lave feil når større avvik ble vektlagt. R^2 verdien på 0.4974 betyr at modellen forklarte omtrent 49.7% av variasjonen i kvalitetsverdiene i testsettet.



Figur 2: Faktiske kvalitetsverdier sammenlignet med modellens predikerte verdier for Random Forest.

Baseline-modellen oppnådde en R^2 verdi på omtrent null, noe som viser at å predikere gjennomsnittlig kvalitet ikke forklarer variasjonen i datasettet. *Lineær regresjon* presterte bedre enn baseline, men hadde høyere prediksjonsfeil enn *Random Forest*. Resultatene tyder derfor på at *Random Forest* klarer å fange opp sammenhenger i datasettet som den lineære modellen ikke fanger opp like godt.

På bakgrunn av resultatene ble *Random Forest* valgt som den endelige modellen og lagret for bruk i webapplikasjonen.

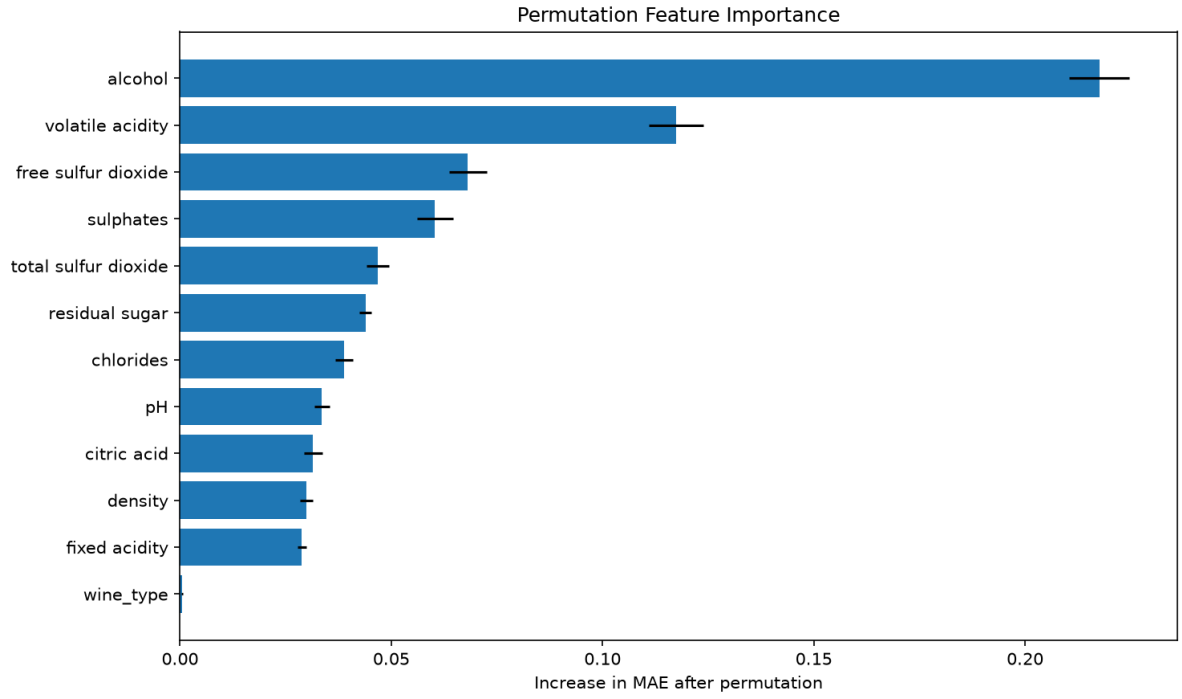
3.4 Feilanalyse og Feature Importance

For å få en bedre forståelse av modellens styrker og svakheter ble det gjennomført en feilanalyse på testsettet. Her ble de absolutte prediksjonsfeilene undersøkt både for rødvin og hvitvin, og for de ulike kvalitetsverdiene.

Resultatene viste at modellen hadde en gjennomsnittlig absolutt feil på 0.3883 for rødvin og 0.4538 for hvitvin. Det altså noe lavere for rødvin enn for hvitvin, men forskjellen er ikke tilstrekkelig til å konkludere med at modellen generelt er bedre på rødvin.

Ved å undersøke feilene fordelt på kvalitetsverdiene kom det frem at modellen presterte best på de vanligste kvalitetsverdiene, særlig 5 og 6. For kvalitetsverdiene 3, 4, 8 og 9 var feilene betydelig større. Dette kan blant annet forklares med at datasettet har en ujevn fordeling. Det finnes mye færre observasjoner med veldig lave og høye kvalitetsverdier. Modellen har dermed mindre treningsdata å lære fra for disse verdiene. I testsettet var det for eksempel kun én observasjon med kvalitetsverdi 9, og resultatet for denne verdien må derfor tolkes med forsiktighet.

Det ble også gjennomført en analyse av *feature importance* ved hjelp av *permutation importance* (scikit-learn, 2026). Metoden undersøker hvor mye modellens prediksjonsytelse svekkes når verdiene til en inputvariabel stokkes om. Dersom modellens feil øker betydelig, tyder det på at variabelen er viktig for prediksjonene.



Figur 3: Permutation importance for inputvariablene i Random Forest-modellen.

Analysen viste at alkoholinnhold var en viktigste variabelen, etterfulgt av *volatile acidity*. *Free sulfur dioxide, sulphates og total sulfur dioxide* hadde også betydning for modellens prediksjoner. Variabelen *wine_type* hadde svært lav målt betydning sammenlignet med de

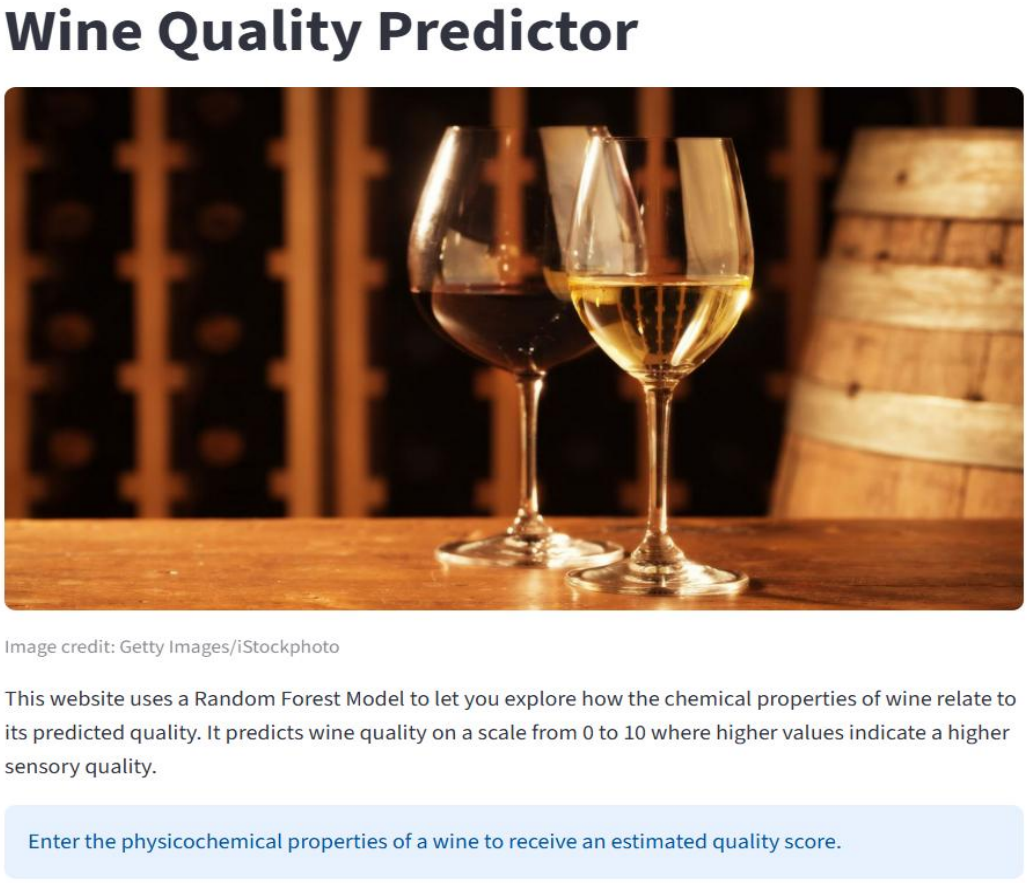
resterende variablene, og peker på at det ikke hadde vært nødvendig å opprette den i utgangspunktet.

Resultatene fra analysen kan brukes til å forstå hvilke egenskaper modellen i størst grad baserer prediksjonene sine på. De kan også legge grunnlag for videre undersøkelser av modellens inputvariabler og mulige forbedringer. Det er likevel viktig å understreke at *feature importance* viser hvor mye modellen er avhengig av en variabel for prediksjonene sine. Den viser ikke nødvendigvis en direkte sammenheng mellom variabelen og vinkvaliteten. Variabler som korrelerer med hverandre kan også påvirke resultatene av analysen.

4 DEPLOYMENT

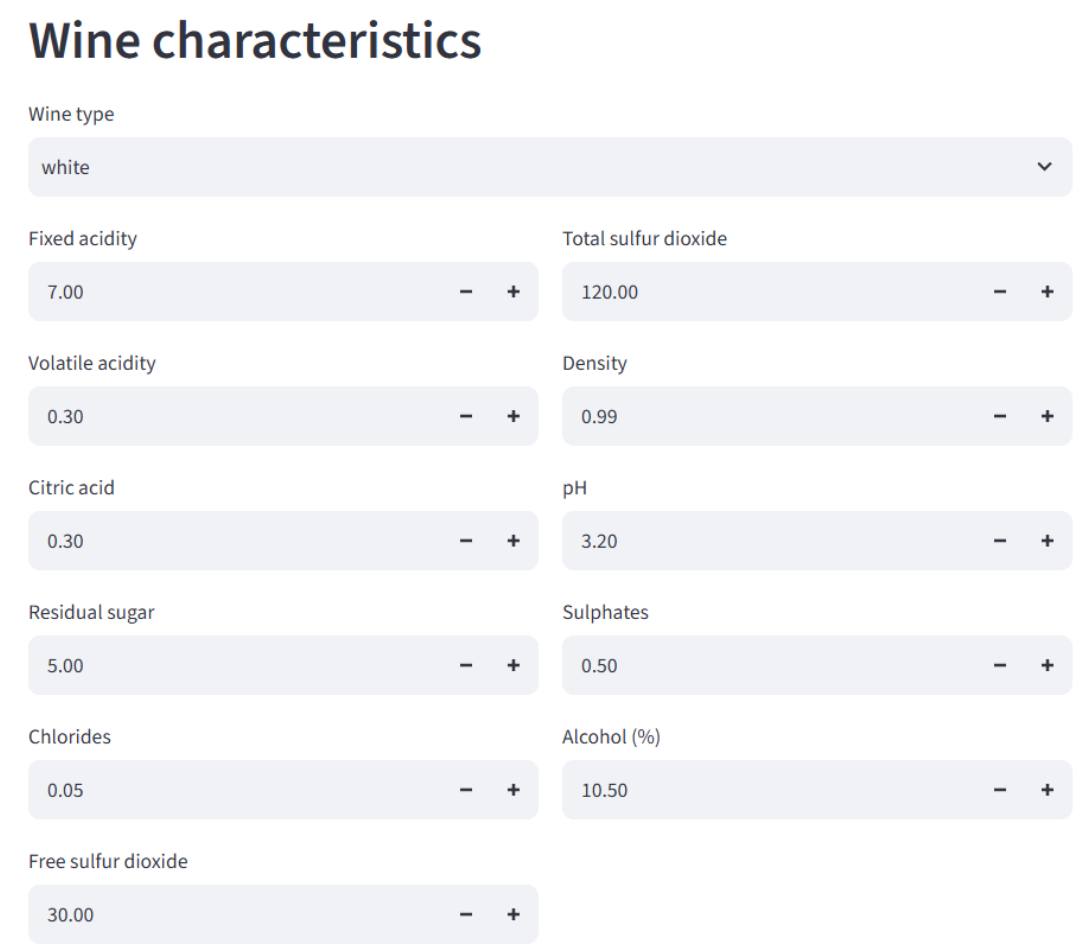
4.1 Deployment og bruk av modellen

Den ferdigtrente Random Forest-modellen ble lagret som en .joblib-fil ved hjelp av Python-biblioteket Joblib. Modellen brukes videre i en webapplikasjon utviklet med Streamlit. Applikasjonen er publisert gjennom Streamlit Community Cloud og er koblet til prosjektets GitHub-repository. Dette gjør det mulig for brukere å åpne og benytte løsningen gjennom en nettleser uten å måtte installere Python eller andre nødvendige biblioteker lokalt.

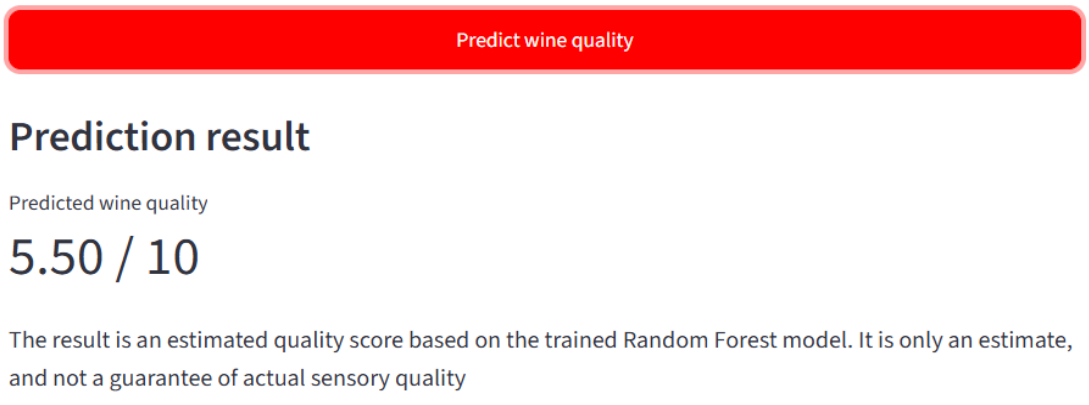


Figur 4: Introduksjon til webapplikasjonen

Webapplikasjonen lar brukeren velge vintype, enten rødvin eller hvitvin, deretter må brukeren legge inn verdier for de 11 fysikalsk-kjemiske egenskapene. Når brukeren sender inn verdiene, benytter applikasjonen den lagrede modellen til å beregne en predikert kvalitetsverdi. Resultatet vises direkte på nettsiden.



Figur 5: Registrering av vinegenskaper



Figur 6: Resultat av prediksjonen

Prediksjonen er som nevnt tidligere kun ment som et estimat basert på vinens kjemiske egenskaper, og ikke som en endelig eller objektiv kvalitetsvurdering. Løsningen er først og fremst utviklet som en demonstrasjon av hvordan maskinlæring kan brukes til å estimere vinkvalitet. Den kan også brukes til å undersøke hvordan ulike kjemiske egenskaper påvirker modellens prediksjoner.

Applikasjonen er tilgjengelig her:
https://wine-quality-predictor-tneawdwyfkyrivmrcf6xt9.streamlit.app/

4.2 Monitorering og vedlikehold

Det er ikke implementert et eget system for automatisk monitorering av modellens ytelse etter deployment. For å kunne vurdere om modellen fortsatt gir pålitelige prediksjoner over tid ville det vært nødvendig å teste den på nye vinprøver, der både de kjemiske måleverdiene og den faktiske kvalitetsvurderingen er kjent. De nye observasjonene kunne blitt brukt til å sammenligne modellens prediksjoner med faktiske vurderinger og undersøke om feilene har blitt større ved hjelp av *MAE* og *RMSE*.

Dersom modellen over tid begynner å gi større feil kan det være nødvendig å trene den på nytt med nyere data. Det ville også være viktig å sørge for at webapplikasjonen og Python-bibliotekene den bruker holdes oppdatert slik at løsningen fortsetter å fungere.

4.3 Videreutvikling

En mulig videreutvikling av løsningen ville vært å gjøre den mer tilgjengelig for vanlige forbrukere. Slik applikasjonen fungerer i dag, må brukeren kjenne til de kjemiske måleverdiene til vinen. Slike opplysninger er vanligvis ikke tilgjengelige på vinflasker eller i vanlige produktbeskrivelser. Dette begrenser hvem som faktisk kan benytte løsningen.

En mulig forbedring ville derfor vært å utvikle en ny modell som krever færre inputvariabler, basert på egenskaper som er enklere for forbrukerne å finne. Dette ville imidlertid krevd at modellen ble trent på nytt med et tilpasset utvalg av inputvariabler som alkoholinnhold, sukker og syre. Det kunne også vært aktuelt å undersøke muligheten for å hente produktinformasjon automatisk fra en ekstern database.

En annen mulig videreutvikling ville vært å teste modellen med et større og mer variert datasett. Dette kunne gitt et bedre grunnlag for å vurdere hvor godt modellen fungerer på andre vintyper og viner fra produsenter som ikke er representert i det opprinnelige datasettet.

Referanser

Bhakta, S. S. (2 de May de 2026). *Random Forest Algorithm in Machine Learning*. Obtenido de geekforgeeks: https://www.geeksforgeeks.org/machine-learning/random-forest-algorithm-in-machine-learning/

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (2009). *ScienceDirect*. Obtenido de Modeling wine preferences by data mining from physicochemical properties: https://www.sciencedirect.com/science/article/abs/pii/S0167923609001377?via%3Dihub

Cortez, P., Cerdeira, A., Almeida, F., Matos, T., & Reis, J. (10 de 06 de 2009). *UCI Machine Learning Repository*. Obtenido de Wine Quality: https://archive.ics.uci.edu/dataset/186/wine+quality

Reddy, N. K. (11 de February de 2026). *Regression Metrics.* Obtenido de geeksforgeeks: https://www.geeksforgeeks.org/machine-learning/regression-metrics/

scikit. (October de 2026). *OneHotEncoder*. Obtenido de scikit: https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.OneHotEncoder?utm_source=chatgpt.com

scikit-learn. (October de 2026). *Feature importances with a forest of trees*. Obtenido de scikit-learn: https://scikit-learn.org/stable/auto_examples/ensemble/plot_forest_importances.html

sklearn. (October de 2026). *StandardScaler*. Obtenido de sklearn: https://sklearn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html?utm_source=chatgpt.com

sma@hvl.no. (Oktober de 2026). *Module 3 - End-to-end machine learning product Lecture 10.* Obtenido de hvl-ml.github.io: https://hvl-ml.github.io/DAT158/slides/3-systems/10-verification.html#/title-slide

sma@hvl.no. (Oktober de 2026). *Module 3 - End-to-end machine learning product Lecture 11.* Obtenido de hvl-ml.github.io: https://hvl-ml.github.io/DAT158/slides/3-systems/11-problems.html#/title-slide

sma@hvl.no. (Oktober de 2026). *Module 3 - End-to-end machine learning product Lecture 9.* Obtenido de hvl-ml.github.io: https://hvl-ml.github.io/DAT158/slides/3-systems/9-ml-project-lifecycle.html#/title-slide

6 KI-ERKLÆRING

Kunstig intelligens (ChatGPT) er benyttet som støtte under arbeidet med prosjektet. Verktøyet er brukt til faglige forklaringer, feilsøking i kode og språklig forbedring av rapporten. KI er også brukt som støtte til å forstå maskinlæringsmetoder og evaluering av modellresultater.

Alt arbeid med implementering, testing og evaluering av modellen er gjennomført og kontrollert av prosjektforfatteren. Prosjektforfatteren har selv ansvar for innholdet, resultatene og konklusjonene i rapporten.